


일단해보기러기~

다분광 데이터 구조

데이터 이름	데이터 개수 및 변수 개수	trX 결측 치 개수	
1_DAT135_12201 2	훈련 데이터 (train_X) 크기: (37440, 20) -> 행(시간): 37440개, 열(변수): 20개 테스트 데이터 (test_X) 크기: (17280, 20) -> 행(시간): 17280개, 열(변수): 20개	0	



네모난 반사판 = '백색 참조 반사판(White Reference Panel)' 또는 '캘리브레이션
보정 패널'

식물 잎사귀가 빛을 얼마나 반사하는지 수치(반사율, **Reflectance**)를 측정하는 정밀
센서

영점 조절(**Calibration**)을 수행

▶ 이 하얀 판을 기준으로 잡고 딸기 잎사귀의 진짜 반사율 수치를 정확하게 계산해라!"
하고 카메라에게 알려주기 위해 딸기 옆에 항상 같이 두고 촬영하는 ****지표면의 인공
기준점**** 출력하신 파장별 이미지(**Band 0** 등)를 보면, 딸기 앞보다 저 반사판 부분이
훨씬 더 붉고 노란색(높은 픽셀 값/반사량)으로 강하게 빛나고 있는 것을 확인할 수
있습니다.

EDA 데이터 셋 구조

1. 데이터셋 구조 요약 (Dataset Structure)

env (환경 데이터) — 수치형 데이터	
train_x.csv (학습용 입력 피쳐)	데이터 특징: 1분 단위로 기록된 모델 학습용 환경 데이터 주요 구성: 외부 환경, 내부 환경, 구동기 제어 이력 등 (총 20개 컬럼)
train_y.csv (학습용 정답 타겟)	데이터 특징: 정답 데이터로, '5분 뒤'의 근권부 환경을 예측 예측 대상 (타겟): 배지 함수율, 배지 EC, 배지 온도
test_x.csv (평가용 입력 피쳐)	데이터 특징: 학습된 모델의 최종 성능 테스트를 위한 입력 데이터 (변수 피쳐)

ms (다파장 영상 데이터)	
파일명 규칙: 촬영위치번호_DAT n_촬영시각 세트로 구성 확장자: Cube.hdr , Cube.raw (하이퍼스펙트럴 해상도: $1280 \times 1024 \times 10 \times \text{text}\{\text{Band}\}$) 활용 목적: 물량율, 병해충 등을 알 수 있는 식물의 생육 상태 및 수분 스트레스 분석 💡 핵심 힌트: 식물이 현재 물을 얼마나 머금고 있는지 등을 수치화하여 train_x 환경 데이터와 함께 사용하면 예측 모델의 강력한 힌트가 됨.	

2. 데이터 규격 및 차원 분석 (Data Shape)

제목	내용
----	----

시간 기준 계산	1분 단위 기록 -> 하루 = 24h * 60m = 1440m 하루 치 데이터: 1,440행
데이터 Matrix 차원 (행(Instances), 열(Features))	train_x: (37440, 20) -> 총 26일치 데이터 (1440 * 26 = 37,440) / DAT 109부터 시작 test_x: (17280, 20) -> 총 12일치 온실 촬영 데이터 (1440 * 12 = 17,280)

하이퍼스펙트럼 해상도 (128*1024*10 band)

3. 모델링 목표 및 핵심 포인트 (타깃값)

제목	내용
타깃 변수 (train_y)	5분 뒤의 배지 함수율, 배지 EC , 배지 온도
모델 구조	1분 단위의 20개 온실 환경(env) 데이터를 입력받아, 5분 뒤의 배지 상태 수치 3개를 동시에 맞추는 구조 (다중 출력/ Multi-output 모델 설계 필요)

- 5분 뒤의 배지 환경 3가지 예측 미션 확인

1. 추가할 피쳐 목록

- **day**: 원본 **time** 문자열에서 날짜 정보(예: 109)만 추출한 정수형 변수 (생육 일수
계산에 활용)
- **hour**: 원본 **time**에서 추출한 0~23시 정보 (식물의 주간/야간 대사 활동 및 광합성
패턴 분석에 필수)
- **minute**: 원본 **time**에서 추출한 0~59분 정보 (1분 단위 시계열 연속성 유지에 활용)
- **이동 평균(Rolling Mean) / 직전 값(Lag) 피쳐** (선택 사항): 현재 온실
환경이 5분 뒤의 근권부 배지 상태에 영향을 미치므로, 주요 변수(내부 온도, 내부
습도, CO2)들의 '최근 5분/15분 평균값' 피쳐를 추가하여 시계열 예측 성능을
극대화함.

2. 제거할 피쳐 목록

- **time**: DAT109 00:00과 같은 형태는 인공지능 모델이 직접 읽을 수 없는
문자열이므로, 위의 **day**, **hour**, **minute**로 분리한 후 반드시 제거해야 함.
- **tube_rail_valve**: [★분석 2 결과 근거] 고유탄(Unique Value) 개수가 단 1개이며,
최솟값과 최댓값이 모두 0.000000입니다. 즉, 전체 실험 기간 동안 단 한 번도

작동하지 않은 불필요한 변수(Constant Feature)이므로 모델의 노이즈를 줄이기 위해 확실히 제거합니다.

3. 피처별 인코딩 전략

- 데이터프레임 내에 존재하는 모든 환경 센서 변수(**temperature**, **humidity** 등)는 소수점을 가지는 연속형 수치(**Float**) 데이터입니다.
- 구동기 제어 데이터(**fcu_fan**, **fcu_pump**, **co2_supply** 등)는 고윳값 개수가 2개이며 0 또는 201(또는 1)로 이루어진 이진형(**Binary**) 제어 플래그 데이터입니다.
- 문자열 변수였던 **time**은 위에서 숫자형 데이터로 완벽하게 분해 완료했으므로, 본 데이터셋에는 원-핫 인코딩(**One-Hot Encoding**)이나 레이블 인코딩(**Label Encoding**)과 같은 추가 범주형 인코딩 전략이 불필요함.

4. 이상치 파악 및 처리 방법

- 이상치 검토 결과 [분석 1 근거]: * 외부 온도 **-5.7 ~ 12.3도**, 내부 온도 **1.5 ~ 26.1도**, 내부 습도 **39 ~ 98%**, CO2 농도 **283 ~ 1742 ppm** 등 온실 환경 센서 데이터가 물리적으로 아주 정상적인 범위 내에 존재하고 있습니다. 통계치를 파괴할 만한 극단적인 센서 오류(예: 온도 **100도**, 습도 **0%** 등)는 발견되지 않았습니다.
- 해당 피처별 처리 방법: * 만약 테스트 데이터셋(**test_X**)에서 통신 음영이나 센서 순간 단선으로 인한 극단적인 이상치(튀는 값)가 발견될 경우, 시계열 데이터의 타임라인 연속성을 보존하기 위해 해당 행을 임의로 삭제하지 않고, 직전의 정상적인 센서 값을 그대로 이어붙이는 전방 보간법(**Forward Fill / ffill()**) 또는 앞뒤 센서 수치의 중간값으로 부드럽게 메워주는 선형 보간법(**Linear Interpolation**)을 적용하여 처리함.

내부 온도(temperature) 분포 및 이상치 확인

